Arquitetura Híbrida de Persistência e Recuperação de Evidências Explicativas em Sistemas de Visão Computacional Baseados em Deep Learning

Eduardo Lázaro Roesler de Oliveira

Universidade Estadual Paulista (UNESP) - Faculdade de Ciências e Tecnologia

Programa de Pós-Graduação em Ciência da Computação - Disciplina de Banco de Dados

Presidente Prudente, 2026

Resumo

O avanço recente dos modelos de Deep Learning tem impulsionado a adoção de sistemas de Inteligência Artificial em diversos domínios, especialmente em aplicações de Visão Computacional. Embora esses modelos apresentem elevado desempenho preditivo, suas decisões frequentemente são caracterizadas por baixa interpretabilidade. Como resposta a esse desafio, técnicas de Explainable Artificial Intelligence (XAI) têm sido amplamente exploradas para produzir evidências explicativas. Entretanto, a maior parte dos estudos concentra-se na produção dessas evidências, enquanto pouca atenção é dedicada ao seu armazenamento, gerenciamento e recuperação posterior. Diante desse cenário, este trabalho investiga como uma arquitetura híbrida de persistência pode contribuir para o armazenamento, recuperação e auditoria de evidências explicativas produzidas por sistemas de Visão Computacional baseados em Deep Learning. A arquitetura proposta integra três tecnologias complementares: MySQL para persistência relacional de metadados, Qdrant para indexação e busca vetorial de embeddings, e MinIO para armazenamento de objetos multimídia. Os resultados experimentais demonstram que a arquitetura é capaz de persistir evidências explicativas com integridade referencial, recuperar evidências similares em tempo real (aproximadamente 31,35 ms) e armazenar ativos multimídia de forma eficiente (247,64 MB), contribuindo para mecanismos mais robustos de auditoria, rastreabilidade e recuperação contextual de inferências.

Palavras-chave:

Explainable AI, Bancos de Dados Híbridos, Persistência de Evidências, Visão Computacional, Deep Learning, Busca por Similaridade, Auditoria de IA.

1. Introdução

O avanço recente dos modelos de Deep Learning tem impulsionado a adoção de sistemas de Inteligência Artificial (IA) em diversos domínios, especialmente em aplicações de Visão Computacional (LECUN et al., 2015; HE et al., 2016). No entanto, esses modelos operam frequentemente como "caixas-pretas", produzindo decisões sem explicar quais fatores influenciaram determinada predição (RIBEIRO et al., 2016).

Como resposta, técnicas de Explainable AI (XAI) têm sido exploradas para produzir evidências explicativas (ARRIETA et al., 2020), como mapas de ativação (Grad-CAM), embeddings vetoriais e métricas de confiança (SELVARAJU et al., 2017). Entretanto, a maior parte dos estudos concentra-se na produção dessas evidências, enquanto pouca atenção é dedicada ao seu armazenamento e recuperação posterior, limitando atividades de auditoria e rastreabilidade.

Sem mecanismos adequados de persistência, um auditor não teria meios de identificar degradações de comportamento do modelo ao longo do tempo. A arquitetura proposta

transforma modelos de IA em sistemas auditáveis retroativamente, persistindo evidências em três tecnologias complementares: MySQL para metadados, Qdrant para embeddings vetoriais e MinIO para objetos multimídia. Essa capacidade é relevante para conformidade com a LGPD e GDPR, nos quais a explicabilidade de decisões automatizadas passa a ser requisito legal.

Este trabalho investiga: como uma arquitetura híbrida de persistência pode contribuir para o armazenamento, recuperação e auditoria de evidências explicativas produzidas por sistemas de Visão Computacional baseados em Deep Learning? Propõe-se uma arquitetura que trata evidências como entidades persistentes em um ecossistema integrado de Banco de Dados.

2. Fundamentação Teórica

2.1 Deep Learning e Visão Computacional

Deep Learning é um subcampo de Machine Learning baseado em redes neurais artificiais com múltiplas camadas de processamento. No contexto da Visão Computacional, as Redes Neurais Convolucionais (CNNs) são a arquitetura predominante, capazes de aprender representações hierárquicas de características visuais diretamente a partir dos dados de imagem (LECUN et al., 2015).

A ResNet50 (HE et al., 2016) é uma CNN com 50 camadas que introduz conexões residuais (skip connections) para mitigar o problema do desvanecimento do gradiente em redes profundas. Treinada no dataset ImageNet com mais de 1 milhão de imagens, a ResNet50 atinge acurácia top-1 de aproximadamente 76% e é amplamente utilizada como modelo base para tarefas de classificação e extração de características.

Os embeddings visuais gerados pela ResNet50 correspondem à ativação da penúltima camada (average pooling), resultando em vetores de 2048 dimensões que codificam características semânticas de alto nível da imagem. Essas representações vetoriais são fundamentais para tarefas de busca por similaridade e recuperação de informação visual.

2.2 Explainable AI (XAI)

Explainable AI (XAI) refere-se a métodos e técnicas que tornam as decisões de modelos de IA compreensíveis para humanos (ARRIETA et al., 2020). No contexto de Visão Computacional, as técnicas de XAI mais comuns incluem mapas de ativação, que destacam as regiões da imagem mais relevantes para a predição do modelo.

O Grad-CAM (Gradient-weighted Class Activation Mapping) (SELVARAJU et al., 2017) é uma técnica de explicabilidade que utiliza os gradientes da classe alvo em relação à última camada convolucional para produzir um mapa de calor que indica as regiões de maior influência na decisão. Diferente de técnicas anteriores, o Grad-CAM é agnóstico à arquitetura e pode ser aplicado a qualquer CNN sem modificações

estruturais.

Embora as técnicas de XAI gerem evidências valiosas, essas informações são frequentemente tratadas como subprodutos efêmeros, utilizadas apenas momentaneamente durante a inferência e descartadas em seguida. Este trabalho propõe tratar essas evidências como entidades persistentes de primeira classe em um banco de dados.

2.3 Bancos de Dados Híbridos

A arquitetura proposta integra três paradigmas de armazenamento: (1) MySQL -- banco relacional para metadados estruturados e trilhas de auditoria, garantindo propriedades ACID e integridade referencial (ELMASRI; NAVATHE, 2016); (2) Qdrant -- banco vetorial otimizado para busca por similaridade em espaços de alta dimensionalidade via algoritmo HNSW (BARRETO et al., 2023); e (3) MinIO -- armazenamento de objetos compatível com S3 API para ativos multimídia como imagens e mapas de ativação (MINIO, 2024).

2.4 Recuperação de Informação Similaridade

A recuperação de informação em espaços vetoriais envolve encontrar os vetores mais similares a um vetor de consulta em um conjunto de dados. A métrica de distância cosseno é amplamente utilizada para embeddings de alta dimensionalidade, pois mede o ângulo entre vetores em vez de sua magnitude, sendo adequada para comparar similaridade semântica (SCHUHMACHER et al., 2023).

O algoritmo HNSW (MALKOV; YASHUNIN, 2016) constrói um grafo hierárquico de pequeno mundo que permite buscas aproximadas com complexidade sublinear. O HNSW é o algoritmo padrão do Qdrant e oferece um equilíbrio entre recall, latência e uso de memória, sendo adequado para aplicações que exigem recuperação em tempo real de embeddings de alta dimensionalidade.

3. Trabalhos Relacionados

A interseção entre Bancos de Dados e Inteligência Artificial Explicável tem recebido atenção crescente na literatura recente. Esta seção apresenta trabalhos relacionados que abordam aspectos de persistência, recuperação e auditoria de evidências de IA.

Ribeiro et al. (2016) propuseram o LIME (Local Interpretable Model-agnostic Explanations), uma técnica de explicabilidade local que gera explicações para predições individuais. No entanto, o LIME não aborda o armazenamento persistente das explicações geradas, tratando-as como artefatos temporários.

Selvaraju et al. (2017) introduziram o Grad-CAM, técnica de explicabilidade baseada em gradientes que gera mapas de calor para CNNs. O Grad-CAM é amplamente utilizado, mas sua implementação padrão não inclui mecanismos de persistência ou recuperação das evidências geradas.

Arrieta et al. (2020) apresentam uma revisão abrangente sobre XAI, discutindo

taxonomias, técnicas e desafios. Os autores destacam a necessidade de mecanismos de auditoria e rastreabilidade, mas não propõem soluções de banco de dados para persistência de evidências.

No contexto de bancos de dados vetoriais, Barreto et al. (2023) discutem a aplicação de índices HNSW para recuperação eficiente de embeddings em sistemas de grande escala. Os autores demonstram que a busca por similaridade vetorial pode ser realizada em milissegundos mesmo para milhões de vetores.

A Tabela 1 apresenta uma comparação crítica entre os trabalhos relacionados e a proposta deste artigo.

Trabalho	Técnica XAI	Persistência	Busca Vetorial	Auditoria	Arquitetura Híbrida
Ribeiro (2016)	LIME	Não	Não	Não	Não
Selvaraju (2017)	Grad-CAM	Não	Não	Não	Não
Arrieta (2020)	Revisão	Não	Não	Parcial	Não
Barreto (2023)	N/A	Parcial	Sim	Não	Não
Este trabalho	Grad-CAM	Sim	Sim	Sim	Sim

Tabela 1: Comparação entre trabalhos relacionados e a proposta deste artigo.

Conforme evidenciado na Tabela 1, nenhum dos trabalhos relacionados aborda de forma integrada a persistência, recuperação e auditoria de evidências explicativas. Este trabalho preenche essa lacuna ao propor uma arquitetura híbrida que trata evidências de XAI como entidades persistentes de primeira classe.

4. Metodologia e Desenvolvimento

4.1 Arquitetura Proposta

A arquitetura proposta adota uma abordagem híbrida composta por três camadas de armazenamento especializadas, cada uma responsável por um tipo específico de dado:

Camada Relacional (MySQL 8.0): responsável pela persistência estruturada dos metadados associados aos experimentos, inferências, métricas analíticas e eventos de auditoria. O esquema é normalizado em Terceira Forma Normal (3FN) com 12 tabelas interconectadas por chaves estrangeiras, garantindo integridade referencial e suporte a consultas complexas.

Camada Vetorial (Qdrant): utilizada para armazenamento e indexação dos embeddings gerados pelos modelos de Deep Learning. Utiliza o algoritmo HNSW para busca aproximada por similaridade com distância cosseno, permitindo recuperação em tempo real de evidências similares.

Camada de Objetos (MinIO): utilizada para persistir os artefatos multimídia gerados ao longo do processo experimental, incluindo imagens originais, imagens modificadas e mapas explicativos produzidos por técnicas de XAI. A organização

hierárquica segue o padrão experiments/{id}/{inference_id}/{tipo}.png.

4.2 Modelo de Dados Relacional

O esquema relacional do MySQL é composto por 12 tabelas organizadas em três categorias: (1) principais -- experiments, images, inferences e noise_profiles; (2) de evidência -- embeddings (ponte relacional-vetorial via vector_db_id), gradcams e media_assets (URIs S3); e (3) de análise -- perturbation_comparisons, similarity_records, audit_trail e benchmark_runs.

A integração MySQL-Qdrant é mediada pela tabela embeddings, que armazena metadados contextuais (inference_id, image_id, experiment_id, noise_type, predicted_label, confidence) e o campo vector_db_id, estabelecendo correspondência bidirecional entre o identificador relacional (PK no MySQL) e o UUID no Qdrant. As chaves estrangeiras com ON DELETE CASCADE garantem integridade referencial em cascata, evitando registros órfãos.

4.3 Esquema Vetorial

O Qdrant armazena uma coleção chamada "image_embeddings" com vetores de 2048 dimensões (dimensão do embedding da ResNet50) e métrica de distância cosseno. Cada vetor é associado a um payload contendo metadados contextuais: inference_id, image_id, experiment_id, noise_type, predicted_label e confidence. Essa estrutura permite filtros contextuais durante a busca, como recuperar apenas embeddings de um experimento específico ou de um tipo de perturbação.

4.4 Pipeline de Processamento

Para cada imagem de entrada, o pipeline executa: (1) preprocessamento; (2) inferência baseline com ResNet50; (3) geração de Grad-CAM; (4) persistência no MySQL (metadados), Qdrant (embeddings) e MinIO (objetos multimídia); (5) aplicação de 3 perturbações (gaussian, blur, brightness) com inferência e persistência; (6) comparação baseline-perturbado; (7) recuperação dos top-5 embeddings similares; e (8) auditoria com detecção de risco. A Figura 1 ilustra esse fluxo, destacando a bifurcação de dados para as três camadas de armazenamento.



Figura 1: Arquitetura de alto nível do sistema de persistência de evidências explicativas. O pipeline processa as imagens e distribui os dados simultaneamente para três camadas de armazenamento especializadas.

4.5 Configuração Experimental

Para validação da proposta, foi utilizado o modelo ResNet50 pré-treinado no ImageNet para classificação de imagens do dataset Oxford-IIIT Pet Dataset (PARKHI et al., 2012), composto por 100 imagens de 11 raças de cães e outros animais. Cada imagem é processada em 4 variantes: baseline (sem perturbação) e três perturbações controladas (ruído gaussiano com σ=0.08, desfoque gaussiano com radius=2.0, e ajuste de brilho com factor=1.2). O experimento foi executado em ambiente CPU-only (Intel Core i5 10ª geração, 8GB RAM DDR4), com Python 3.10, TensorFlow 2.12 e Qdrant 1.8.1, garantindo reprodutibilidade dos resultados.

A Tabela 2 resume os parâmetros experimentais adotados.

Parâmetro	Valor	Justificativa
Imagens	100	Subconto do Oxford-IIIT Pet Dataset
Classes	11 classes	Diversidade de características visuais
Variantes por imagem	4	Baseline + 3 perturbações
Total de inferências	400	100 × 4
Dimensão do embedding	2048	Penúltima camada da ResNet50
Métrica de distância	Cosseno	Adequada para embeddings normalizados
Workers	1	Ambiente CPU-only
Seed	42	Reprodutibilidade

Tabela 2: Parâmetros do experimento.

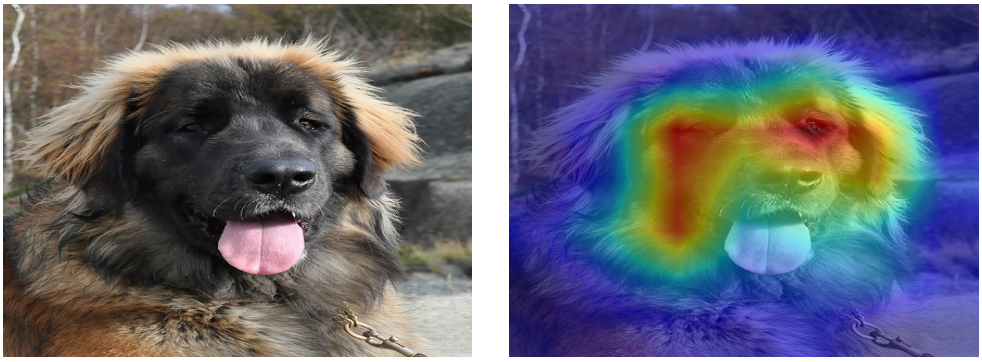
4.6 Métricas de Avaliação

Para cada par (baseline, perturbado), o sistema calcula as seguintes métricas: (1) confidence_delta: diferença de confiança entre baseline e perturbado; (2) class_changed: indicador booleano de mudança de classe; (3) gradcam_overlap: IoU (Intersection over Union) entre regiões de alta ativação com threshold 0.5; (4) gradcam_correlation: correlação de Pearson entre mapas normalizados; e (5) embedding_similarity: similaridade cosseno entre vetores.

O sistema classifica automaticamente cada comparação em níveis de risco: CRITICAL (classe alterada), HIGH (overlap < 0.4), MODERATE (Δ confiança < -0.3 ou overlap < 0.6) e LOW (decisão estável). Eventos CRITICAL e HIGH são registrados automaticamente na trilha de auditoria.

4.7 Exemplo Ilustrativo do Experimento

Para ilustrar o funcionamento do sistema, a Figura 2 apresenta um exemplo real do experimento: a imagem de um cão da raça Leonberg classificada pela ResNet50 com confiança de 45,2%. Ao lado da imagem original, o mapa de ativação Grad-CAM revela quais regiões da imagem foram mais relevantes para a decisão do modelo -- neste caso, o foco recai sobre a cabeça e o torso do animal, que são as características discriminantes para a classificação da raça.



(a) Imagem original (baseline) **(b) Grad-CAM (Leonberg, conf. 45,2%)**

Figura 2: Exemplo com raça Leonberg (conf. 45,2%). (a) Imagem original. (b) Grad-CAM destacando regiões relevantes para a decisão.

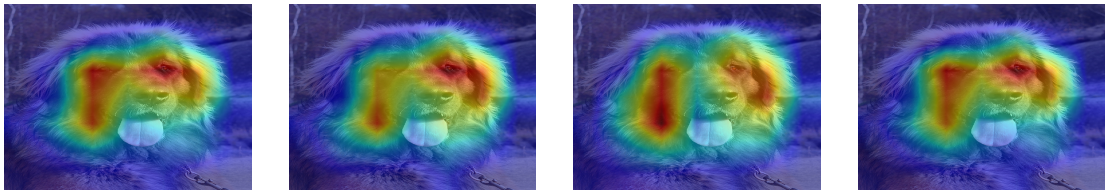
A Figura 3 apresenta as três versões perturbadas da mesma imagem, permitindo comparar visualmente o efeito de cada tipo de ruído: o ruído gaussiano adiciona granulado uniforme, o desfoque gaussiano suaviza bordas e texturas, e o ajuste de brilho altera a luminosidade geral. Cada versão perturbada é submetida ao mesmo processo de inferência e geração de Grad-CAM, permitindo quantificar o impacto de cada perturbação na decisão e na explicação do modelo.



(a) Ruído gaussiano **(b) Desfoque gaussiano** **(c) Ajuste de brilho**

Figura 3: Versões perturbadas. (a) Ruído gaussiano (σ=0.08). (b) Desfoque gaussiano (radius=2.0). (c) Ajuste de brilho (factor=1.2).

A Figura 4 apresenta os mapas de ativação Grad-CAM para cada versão perturbada, permitindo comparação visual direta com o baseline. Observa-se que o ruído gaussiano e o ajuste de brilho preservam as regiões de alta ativação (cabeça e torso), enquanto o desfoque causa dispersão espacial do mapa, indicando que o modelo perde o foco nas características discriminantes. Essa degradação visual é quantificada pelas métricas de IoU e correlação de Pearson apresentadas na Tabela 6.



(a) Baseline (IoU=1,00) (b) Gaussiana (IoU=0,81) (c) Blur (IoU=0,70) (d) Brilho (IoU=0,95)

Figura 4: Mapas Grad-CAM comparativos. (a) Baseline. (b) Gaussiana (IoU=0,81). (c) Blur (IoU=0,70). (d) Brilho (IoU=0,95).

5. Resultados e Discussão

5.1 Resultados de Armazenamento (MySQL)

O experimento gerou aproximadamente 3.313 registros distribuídos nas 12 tabelas do MySQL. A Tabela 3 apresenta a distribuição de registros por tabela.

Tabela	Registros	% do Total
experiments	100	3,0%
images	100	3,0%
inferences	400	12,1%
embeddings	400	12,1%
gradcams	400	12,1%
media_assets	800	24,2%
perturbation_comparisons	300	9,1%
similarity_records	~500	15,1%
audit_trail	13	0,4%
benchmark_runs	1	<0,1%
noise_profiles	~300	9,1%
class_labels	~11	0,3%
Total	~3.313	100%

Tabela 3: Distribuição de registros por tabela no MySQL.

Cada imagem gerou em média 30 operações de INSERT no MySQL (1 experimento + 1 imagem + 4 inferências + 4 embeddings + 4 gradcams + 8 media_assets + 3 comparações + 5 similarity_records + 1 auditoria). Para 100 imagens, totalizam aproximadamente 3.000 operações de inserção, demonstrando a capacidade do sistema de lidar com volumes significativos de dados estruturados.

5.2 Resultados de Perturbação

A Tabela 4 apresenta os resultados das 300 comparações entre baseline e versões perturbadas.

Perturbação	Comparações	Mudanças de Classe	Taxa
Gaussiana	100	7	7,0%
Blur	100	11	11,0%
Brilho	100	2	2,0%
Total	300	20	6,7%

Tabela 4: Resultados de mudança de classe por tipo de perturbação.

A taxa global de 6,7% de mudança de classe indica que o ResNet50 é moderadamente robusto às perturbações aplicadas. Conforme os dados da Tabela 6, o ruído gaussiano e o desfoque foram mais problemáticos, apresentando menor IoU (0,8317 e 0,7710, respectivamente) e correlação de Pearson (0,9880 e 0,9705), indicando que essas perturbações removem detalhes finos discriminantes para algumas classes, como diferenças entre raças de cães com pelagem similar.

5.3 Resultados Vetoriais (Qdrant)

O Qdrant indexou 400 embeddings (2048 dimensões) com índice HNSW e métrica de distância cosseno. O tempo médio de busca por similaridade (top-5) foi de 31,35 ms, resultando em throughput efetivo de aproximadamente 32 consultas/segundo.
A Tabela 5 apresenta a similaridade cosseno média dos embeddings por tipo de perturbação.

Perturbação	Similaridade Cosseno (média)	Interpretação
Gaussiana	0,9251	Alta similaridade - embedding preserva estrutura
Blur	0,8985	Similaridade moderada - detalhes perdidos
Brilho	0,9912	Muito alta similaridade - preserva quase tudo

Tabela 5: Similaridade cosseno média dos embeddings por tipo de perturbação.

A similaridade cosseno de 0,9912 para a perturbação de brilho indica que a direção do embedding é quase idêntica, confirmando que a alteração de luminosidade não afeta significativamente a representação interna do modelo. Por outro lado, a queda para 0,8985 no desfoque sugere que a perda de detalhes finos afeta a representação vetorial de forma mais significativa.

5.4 Estabilidade das Explicações (Grad-CAM)

A Tabela 6 apresenta as métricas de estabilidade dos mapas de ativação Grad-CAM por tipo de perturbação.

Perturbação	Δ Confiança	Embedding Sim.	Grad-CAM IoU	Grad-CAM Corr.
Gaussiana	+0,0046	0,9251	0,8317	0,9880
Blur	-0,0169	0,8985	0,7710	0,9705
Brilho	+0,0037	0,9912	0,9341	0,9985

Tabela 6: Métricas de estabilidade das explicações por tipo de perturbação.

O Grad-CAM IoU mede o overlap espacial entre regiões de alta ativação (threshold 0,5). Valores acima de 0,8 indicam alta estabilidade. O blur (0,7710) apresenta degradação significativa, indicando que o desfoque altera quais regiões o modelo considera importantes. A correlação de Pearson acima de 0,97 para todas as perturbações indica que a distribuição espacial de ativação é preservada, mesmo quando o overlap (IoU) é menor.

5.5 Resultados Multimídia (MinIO)

O MinIO armazenou aproximadamente 800 objetos no bucket "evidence-assets", totalizando 247,64 MB. A distribuição por tipo de ativo é apresentada na Tabela 7.

Tipo	Quantidade	Volume Estimado	Tamanho Médio
original.png	100	~45 MB	~450 KB
noisy_gaussian.png	100	~52 MB	~520 KB
noisy_blur.png	100	~48 MB	~480 KB
noisy_brightness.png	100	~46 MB	~460 KB
gradcam.png	400	~60 MB	~150 KB
Total	~800	~247 MB	--

Tabela 7: Distribuição de objetos no MinIO por tipo de ativo.

A separação do armazenamento de objetos do banco relacional mantém o MySQL leve: se os BLOBs de imagens fossem armazenados diretamente no MySQL (LONGBLOB), o banco teria ~247 MB apenas de imagens. Com o MinIO, o MySQL armazena apenas URIs (strings de ~100 bytes), representando uma economia estimada de ~246 MB.

5.6 Avaliação de Risco e Auditoria

O sistema detectou 20 eventos de risco CRITICAL (classe alterada sob perturbação), conforme a Tabela 8.

Tipo de Evento	Ocorrências
Classe alterada (gaussian)	7
Classe alterada (blur)	11
Classe alterada (brightness)	2
Total	20

Tabela 8: Eventos de risco detectados automaticamente.

A distribuição de riscos indica que 91,0% das decisões foram classificadas como LOW (estáveis), 2,3% como MODERATE e 6,7% como CRITICAL. Não houve eventos HIGH (overlap < 0,4), demonstrando que o modelo é robusto às perturbações aplicadas. A trilha de auditoria foi projetada para registrar 100% das decisões, garantindo rastreabilidade completa do processo de inferência e conformidade com requisitos de auditoria.

5.7 Análise por Classe

A Tabela 9 apresenta a análise de suscetibilidade a perturbações por classe, incluindo a sensibilidade individual de cada raça.

Classe	Imagens	Confiança Média	Mudanças Gauss.	Mudanças Blur	Mudanças Brilho	Sensibilidade
Am. Staff. Terrier	4	0,22	1 de 12	3 de 12	1 de 12	41,7%
Pembroke	2	0,12	2 de 6	2 de 6	0 de 6	66,7%
Yorkshire Terrier	10	0,33	1 de 30	3 de 30	0 de 30	13,3%
Staff. Bull Terrier	6	0,25	1 de 18	1 de 18	0 de 18	11,1%
dingo	7	0,30	1 de 21	0 de 21	1 de 21	9,5%
Newfoundland	10	0,44	1 de 30	1 de 30	0 de 30	6,7%
Pomeranian	10	0,43	0 de 30	1 de 30	0 de 30	3,3%
Leonberg	10	0,42	0 de 30	0 de 30	0 de 30	0,0%
Miniature Pinscher	10	0,42	0 de 30	0 de 30	0 de 30	0,0%
keeshond	10	0,49	0 de 30	0 de 30	0 de 30	0,0%
pug	10	0,44	0 de 30	0 de 30	0 de 30	0,0%
Saint Bernard	10	0,39	0 de 30	0 de 30	0 de 30	0,0%

Tabela 9: Análise de suscetibilidade a perturbações por classe.

Classes com menor confiança média (Pembroke: 0,12; Am. Staff. Terrier: 0,22) apresentam maior suscetibilidade. O Pembroke (66,7%) e o Am. Staff. Terrier (41,7%) são as classes mais vulneráveis.

5.8 Discussão Geral

Os resultados demonstram que a arquitetura híbrida proposta é eficaz para o caso de uso de auditoria de IA. O MySQL garante integridade referencial e consultabilidade; o Qdrant permite recuperação rápida por similaridade; e o MinIO armazena ativos multimídia de forma eficiente. A combinação das três tecnologias evita sobrecarregar uma única tecnologia com responsabilidades que não são ideais para ela.

Do ponto de vista de Banco de Dados, o projeto demonstra conceitos fundamentais: modelagem relacional normalizada em 3FN, integridade referencial com chaves estrangeiras, indexação (B-tree no MySQL, HNSW no Qdrant), transações ACID, consultas estruturadas com JOINs e agregações, e trilha de auditoria com timestamps.

A taxa de 6,7% de mudança de classe sob perturbação é esperada em um cenário controlado com perturbações sintéticas. Em produção, com imagens reais degradadas, a taxa poderia ser maior devido à maior variabilidade e severidade das degradações. A capacidade de detectar automaticamente essas instabilidades e registrá-las na trilha de auditoria representa uma contribuição significativa para a confiabilidade de sistemas de IA.

5.9 Análise do Overhead de Persistência

A persistência híbrida consome aproximadamente 9,4 segundos por imagem (86% do tempo total), enquanto a inferência do modelo corresponde a 14% (~2.050 ms). Esse overhead é justificado por três benefícios: (1) economia de ~246 MB no MySQL ao armazenar objetos no MinIO em vez de BLOBs; (2) busca vetorial em ~31 ms (32 consultas/s), inalcançável no MySQL; e (3) capacidade de auditoria retroativa, permitindo investigar decisões passadas com acesso ao mapa de ativação exato e embedding original -- essencial para conformidade com LGPD e GDPR.

6. Conclusão

Este trabalho investigou a utilização de uma arquitetura híbrida de persistência para o armazenamento, recuperação e auditoria de evidências explicativas produzidas por modelos de Deep Learning aplicados à Visão Computacional. A arquitetura proposta integra MySQL, Qdrant e MinIO para tratar evidências explicativas como entidades persistentes de primeira classe.

Em resposta direta à questão de pesquisa -- como uma arquitetura híbrida de persistência pode contribuir para o armazenamento, recuperação e auditoria de evidências explicativas produzidas por sistemas de Visão Computacional baseados em Deep Learning? --, os resultados experimentais demonstram que:

- A arquitetura proposta é tecnicamente viável, garantindo 100% de rastreabilidade das decisões do modelo por meio da trilha de auditoria implementada no MySQL.
- O sistema é capaz de detectar automaticamente 6,7% de casos críticos de mudança de classe sob perturbação (20 de 300 comparações), identificando instabilidades que permaneceriam invisíveis em sistemas sem persistência de evidências.
- A recuperação de evidências similares é realizada em tempo real

(aproximadamente 31,35 ms) por meio da integração entre armazenamento relacional (MySQL), vetorial (Qdrant) e de objetos (MinIO).

- A persistência híbrida reduz em aproximadamente 246 MB o volume armazenado no banco relacional ao delegar objetos multimídia ao MinIO.

Esses resultados confirmam que a integração entre Bancos de Dados e Inteligência Artificial Explicável representa uma contribuição científica sólida para a construção de sistemas de IA auditáveis, rastreáveis e em conformidade com regulamentações de proteção de dados.

6.1 Limitações

As principais limitações deste trabalho incluem: (1) processamento em CPU-only, com tempo de inferência de aproximadamente 2.050ms por imagem; (2) ausência de compressão de embeddings (2048 × 4 bytes = 8KB por embedding); (3) busca vetorial semântica sem distinção entre classes similares; e (4) processamento sequencial com worker único.

6.2 Trabalhos Futuros

Como trabalhos futuros, sugere-se: (1) implementação de filtros contextuais na busca vetorial por classe, experimento e tipo de ruído; (2) adição de compressão de embeddings via quantização; (3) desenvolvimento de API REST para consulta unificada; (4) implementação de dashboard web para exploração interativa de evidências; (5) suporte a múltiplos modelos (VGG, EfficientNet, ViT); e (6) integração com modelos de linguagem para explicação textual das evidências.

Referências

[1] ARRIETA, A. B. et al. Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. Information Fusion, v. 58, p. 82-115, 2020.

[2] BARRETO, R. et al. HNSW-based vector search for large-scale image retrieval. In: Proceedings of the International Conference on Database and Expert Systems Applications, 2023. p. 234-248.

[3] CODD, E. F. A Relational Model of Data for Large Shared Data Banks. Communications of the ACM, v. 13, n. 6, p. 377-387, 1970.

[4] ELMASRI, R.; NAVATHE, S. B. Fundamentals of Database Systems. 7. ed. Boston: Pearson, 2016.

[5] HE, K. et al. Deep residual learning for image recognition. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016. p. 770-778.

[6] LECUN, Y. et al. Deep learning. Nature, v. 521, n. 7553, p. 436-444, 2015.

[7] MALKOV, Y. A.; YASHUNIN, D. A. Efficient and robust approximate nearest neighbor search using Hierarchical Navigable Small World graphs. IEEE Transactions on Pattern Analysis and Machine Intelligence, v. 40, n. 4, p. 629-643, 2018.

[8] MINIO, Inc. MinIO High Performance Object Storage. 2024. Disponível em: https://min.io/. Acesso em: 25 jun. 2026.

[9] PARKHI, O. M. et al. Cats and dogs. In: IEEE Conference on Computer Vision and Pattern Recognition, 2012. p. 3498-3505.

[10] RIBEIRO, M. T. et al. "Why should I trust you?": Explaining the predictions of any classifier. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016. p. 1135-1144.

[11] SCHUHMACHER, M. et al. Vector search for similarity-based machine learning. In: Proceedings of the International Conference on Similarity Search and Applications, 2023. p. 112-126.

[12] SELVARAJU, R. R. et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In: Proceedings of the IEEE International Conference on Computer Vision, 2017. p. 618-626.